به نام خدا

یادگیری ماشین

تمرین تئوری ـ سری اول

نیم‌سال تحصیلی ۴۰۵۱

نام

حامی عبادزاده سمنانی

شماره دانشجویی

40552521603

۱ انواع یادگیری

> توضیح انواع یادگیری‌ها، به‌جز یادگیری تقویتی، به‌صورت مفهومی به همراه مثال.

پاسخ

۱.۱ Supervised Learning

در یادگیری نظارت‌شده، مجموعه‌دادهٔ آموزشی شامل نمونه‌هایی است که برای هر یک، برچسب یا مقدار هدف مشخصی وجود دارد. هدف، یادگیری رابطه‌ای میان ویژگی‌های ورودی و خروجی‌های متناظر است؛ به‌گونه‌ای که مدل بتواند خروجی نمونه‌های جدید و مشاهده‌نشده را پیش‌بینی کند.

این نوع یادگیری به دو مسئلهٔ اصلی تقسیم می‌شود:

- **Regression:** در رگرسیون، متغیر هدف معمولاً پیوسته و عددی است و مدل تلاش می‌کند مقدار آن را برای ورودی‌های جدید تخمین بزند.
- **Classification:** در دسته‌بندی، متغیر هدف گسسته است و به مجموعه‌ای از کلاس‌های ازپیش‌تعریف‌شده تعلق دارد. هدف مدل، تعیین کلاس مناسب برای هر ورودی جدید است.

۱.۱.۱ تمایز مفهومی رگرسیون و دسته‌بندی

در رگرسیون، مقدار پیش‌بینی‌شده لزوماً نباید یکی از مقادیر مشاهده‌شده در مجموعهٔ آموزشی باشد؛ برای مثال، مدل می‌تواند مقداری میان دو مقدار آموزشی یا حتی خارج از بازهٔ آن‌ها پیش‌بینی کند. در مقابل، در دسته‌بندی، خروجی نهایی مدل باید یکی از کلاس‌های تعریف‌شده برای مسئله باشد و نمی‌تواند کلاس جدیدی خارج از این مجموعه ایجاد کند.

۲.۱.۱ مثال‌ها

- **رگرسیون:** پیش‌بینی قیمت یک خانه بر اساس متراژ، موقعیت مکانی و سال ساخت آن. قیمت پیش‌بینی‌شده می‌تواند مقداری باشد که دقیقاً در هیچ‌یک از نمونه‌های آموزشی وجود نداشته است.
- **دسته‌بندی:** تشخیص خوش‌خیم یا بدخیم بودن یک تومور بر اساس ویژگی‌های اندازه‌گیری‌شدهٔ آن. مدل، نمونهٔ جدید را در یکی از دو کلاس «خوش‌خیم» یا «بدخیم» قرار می‌دهد.

۲.۱ Unsupervised Learning

در یادگیری بدون نظارت، برخلاف یادگیری نظارت‌شده، داده‌های آموزشی فاقد برچسب یا مقدار هدف مشخص هستند. در این نوع یادگیری، هدف اصلی کشف ساختارها، الگوها و روابط پنهان میان داده‌ها است؛ بدون آنکه خروجی مطلوب هر نمونه از پیش در اختیار مدل قرار گرفته باشد.

برخی از مسائل مهم در یادگیری بدون نظارت عبارت‌اند از:

- **Clustering:** هدف، تقسیم داده‌ها به گروه‌هایی است که نمونه‌های درون هر گروه از نظر ویژگی‌هایشان به یکدیگر شباهت بیشتری داشته باشند. برخلاف دسته‌بندی در یادگیری نظارت‌شده، این گروه‌ها از پیش برچسب‌گذاری نشده‌اند و مدل ساختار گروه‌بندی را از خود داده‌ها کشف می‌کند.
- **Dimensionality Reduction**
- **Density Estimation / Anomaly Detection:** در تخمین چگالی، هدف، شناخت توزیع احتمالی داده‌ها و تعیین نواحی پرتراکم و کم‌تراکم فضای ویژگی‌ها است. در تشخیص ناهنجاری نیز تلاش می‌شود نمونه‌هایی شناسایی شوند که با الگوهای معمول داده‌ها سازگاری ندارند. کم بودن چگالی می‌تواند نشانه‌ای از ناهنجاری باشد، اما لزوماً هر نمونه در نواحی کم‌تراکم، ناهنجار نیست.

۱.۲.۱ مثال‌ها

- **خوشه‌بندی:** فرض کنید فروشگاهی اطلاعاتی از میزان خرید، تعداد مراجعه و نوع محصولات خریداری‌شده توسط مشتریان خود در اختیار دارد. بدون آنکه گروه‌بندی مشتریان از پیش مشخص شده باشد، می‌توان با استفاده از خوشه‌بندی، مشتریانی با رفتار خرید مشابه را در گروه‌های مشترک قرار داد.
- **تخمین چگالی و تشخیص ناهنجاری:** فرض کنید داده‌های حسگرهای یک دستگاه صنعتی در شرایط عملکرد عادی جمع‌آوری شده‌اند. با تخمین توزیع این داده‌ها می‌توان محدوده‌های رایج عملکرد دستگاه را شناسایی کرد. در نتیجه، مشاهده مقادیر بسیار نامحتمل یا الگوهای غیرمعمول می‌تواند نشانه‌ای از بروز نقص احتمالی در دستگاه باشد.

۳.۱ Semi-supervised Learning

در یادگیری نیمه‌نظارت‌شده، مجموعه‌داده آموزشی شامل تعداد محدودی از نمونه‌های برچسب‌دار و تعداد بیشتری از نمونه‌های بدون برچسب است. هدف، استفاده هم‌زمان از اطلاعات نمونه‌های برچسب‌دار و ساختار موجود در داده‌های بدون برچسب برای بهبود عملکرد مدل است.

این روش به‌ویژه زمانی کاربرد دارد که جمع‌آوری داده آسان باشد، اما برچسب‌گذاری آن به زمان، هزینه یا دانش تخصصی نیاز داشته باشد.

یکی از روش‌های رایج، برچسب‌گذاری Pseudo-labeling است؛ به این صورت که ابتدا مدل با داده‌های برچسب‌دار آموزش می‌بیند و سپس برای نمونه‌های بدون برچسب پیش‌بینی انجام می‌دهد. پیش‌بینی‌هایی که مدل از صحت آن‌ها اطمینان بالایی دارد، به‌عنوان برچسب‌های موقت در ادامه آموزش استفاده می‌شوند.

البته همه روش‌های نیمه‌نظارت‌شده مبتنی بر تولید برچسب نیستند؛ برای مثال، برخی روش‌ها از شباهت میان نمونه‌ها یا سازگاری پیش‌بینی‌های مدل در برابر تغییرات کوچک ورودی استفاده می‌کنند.

۱.۳.۱ تمایز با یادگیری نظارت‌شده

در یادگیری نظارت‌شده، تابع یادگیری با استفاده از نمونه‌های برچسب‌دار آموزش می‌بیند؛ اما در یادگیری نیمه‌نظارت‌شده، داده‌های بدون برچسب نیز در فرایند آموزش نقش دارند. بنابراین تفاوت اصلی در نوع خروجی مدل نیست، بلکه در اطلاعاتی است که هنگام آموزش مورد استفاده قرار می‌گیرد.

همچنین برچسب‌های تولیدشده توسط خود مدل لزوماً صحیح نیستند و نباید با برچسب‌های واقعی یکسان در نظر گرفته شوند.

۲.۳.۱ مثال

فرض کنید بیمارستانی یک میلیون تصویر رادیولوژی از قفسه سینه در اختیار دارد، اما تنها دو هزار تصویر توسط متخصصان برچسب‌گذاری شده‌اند. می‌توان ابتدا یک مدل دسته‌بندی را با تصاویر برچسب‌دار آموزش داد و سپس با بهره‌گیری از اطلاعات تصاویر بدون برچسب، عملکرد آن را بهبود بخشید؛ بدون آنکه لازم باشد تمام تصاویر به‌صورت دستی برچسب‌گذاری شوند.

۴.۱ Self-supervised Learning

در یادگیری خودنظارت‌شده، برخلاف یادگیری نظارت‌شده، نیازی به برچسب‌گذاری دستی داده‌ها برای وظیفه آموزشی اولیه نیست. در عوض، با استفاده از ساختار خود داده‌ها، یک مسئله پیش‌بینی تعریف می‌شود که اطلاعات لازم برای تعیین پاسخ صحیح آن از خود داده قابل استخراج است.

به عبارت دیگر، مدل مسئله‌ای را حل می‌کند که پاسخ آن از پیش در داده‌ها وجود دارد، اما بخشی از اطلاعات ورودی از مدل پنهان شده یا به شکل دیگری در اختیار آن قرار می‌گیرد.

هدف معمولاً یادگیری بازنمایی‌های مفیدی از داده‌ها است که بتوان از آن‌ها در مسائل دیگر نیز استفاده کرد.

۱.۴.۱ مثال

در آموزش مدل‌های زبانی، می‌توان بخشی از یک جمله را در اختیار مدل قرار داد و از آن خواست کلمه بعدی را پیش‌بینی کند.

در این حالت، کلمه صحیح از خود متن آموزشی استخراج می‌شود و نیازی نیست انسانی برای هر جمله برچسب جداگانه‌ای تعیین کند.

مدل با حل مکرر این مسئله، الگوهای زبانی و روابط میان کلمات را یاد می‌گیرد. از دانش حاصل می‌توان در وظایف دیگری مانند دسته‌بندی متن یا پاسخ‌گویی به پرسش‌ها استفاده کرد.

۲ تعداد پارامترهای چندجمله‌ای

> تعداد پارامترهای چندجمله‌ای درجه M در فضای D بعدی و تحلیل رفتار آن با افزایش بعد.

پاسخ

۱.۲ فرمول‌بندی چندجمله‌ای در فضای چندبعدی

فرض کنید $D \geq 1$ و $M \geq 0$ اعداد صحیح باشند و بردار ورودی $\mathbf{x} = (x_1, \ldots, x_D) \in \mathbb{R}^D$ باشد. یک چندجمله‌ای عمومی با **درجه کل حداکثر** M را می‌توان به صورت

$$f(\mathbf{x}) = \sum_{\substack{\boldsymbol{\alpha} \in \mathbb{Z}_{\geq 0}^D \\ |\boldsymbol{\alpha}| \leq M}} w_{\boldsymbol{\alpha}}\, \mathbf{x}^{\boldsymbol{\alpha}}$$

نوشت، که در آن

$$\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_D), \qquad |\boldsymbol{\alpha}| = \sum_{j=1}^{D} \alpha_j, \qquad \mathbf{x}^{\boldsymbol{\alpha}} = \prod_{j=1}^{D} x_j^{\alpha_j}.$$

تمام توان‌ها اعداد صحیح نامنفی هستند؛ زیرا در تعریف چندجمله‌ای، توان منفی وجود ندارد. هر بردار توان $\boldsymbol{\alpha}$ یک **تک‌جمله‌ای متمایز** را مشخص می‌کند. برای مثال، x_1x_2 و x_2x_1 هر دو به بردار $\boldsymbol{\alpha} = (1, 1)$ مربوط‌اند و نباید دو بار شمرده شوند.

۲.۲ قضیه: تک‌جمله‌ای‌های متمایز یک پایه تشکیل می‌دهند

فضای برداری چندجمله‌ای‌های حقیقی با درجه کل حداکثر M را چنین تعریف می‌کنیم:

$$\mathcal{P}_{D,M} = \big\{ p \in \mathbb{R}[x_1, \ldots, x_D] : \deg p \leq M \big\}.$$

قضیه. مجموعه

$$\mathcal{B}_{D,M} = \left\{\mathbf{x}^{\boldsymbol{\alpha}} : \boldsymbol{\alpha} \in \mathbb{Z}^D_{\geq 0},\ |\boldsymbol{\alpha}| \leq M\right\}$$

یک پایه برای $\mathcal{P}_{D,M}$ است.

۱.۲.۲ اثبات پوشا بودن

طبق تعریف چندجمله‌ای، هر عضو $\mathcal{P}_{D,M}$ ترکیبی خطی و متناهی از تک‌جمله‌ای‌های مجموعه $\mathcal{B}_{D,M}$ است؛ پس

$$\operatorname{span}(\mathcal{B}_{D,M}) = \mathcal{P}_{D,M}.$$

۲.۲.۲ اثبات استقلال خطی با استقرا

نشان می‌دهیم اگر یک ترکیب خطی از تک‌جمله‌ای‌های متمایز روی تمام $\mathbb{R}^D$ صفر باشد، تمام ضرایب آن صفرند. اثبات با استقرا بر تعداد متغیرها D انجام می‌شود.

پایه استقرا: $(D = 1)$. اگر چندجمله‌ای تک‌متغیره

$$p(x) = \sum_{k=0}^{M} c_k x^k$$

برای تمام $x \in \mathbb{R}$ صفر باشد، بی‌نهایت ریشه دارد. از آنجا که یک چندجمله‌ای ناصفر از درجه حداکثر M بیش از M ریشه متمایز ندارد، باید همه ضرایب c_k صفر باشند.

گام استقرا. فرض کنید ادعا برای چندجمله‌ای‌های $D-1$ متغیره درست باشد. اگر چندجمله‌ای D متغیره $p(\mathbf{x})$ برای تمام $\mathbf{x} \in \mathbb{R}^D$ صفر باشد، آن را برحسب توان‌های x_D می‌نویسیم:

$$p(x_1, \ldots, x_D) = \sum_{k=0}^{M} x_D^k\, q_k(x_1, \ldots, x_{D-1}),$$

که هر q_k چندجمله‌ای با حداکثر $D-1$ متغیر و درجه کل حداکثر $M-k$ است. هر مقدار ثابت دلخواه برای $(x_1, \ldots, x_{D-1})$ در نظر بگیرید. عبارت بالا نسبت به x_D یک چندجمله‌ای تک‌متغیره است که برای **تمام** $x_D \in \mathbb{R}$ صفر می‌شود. پس طبق حالت پایه، تمام ضرایب آن باید صفر باشند:

$$q_k(x_1, \ldots, x_{D-1}) = 0, \qquad k = 0, \ldots, M.$$

چون مقادیر $(x_1, \ldots, x_{D-1})$ دلخواه بودند، هر q_k روی کل $\mathbb{R}^{D-1}$ همانی صفر است. با فرض استقرا، همه ضرایب تک‌جمله‌ای‌های هر q_k صفرند؛ بنابراین تمام ضرایب p نیز صفر هستند.

پس تک‌جمله‌ای‌های متمایز مستقل خطی‌اند و به همراه خاصیت پوشا بودن، نتیجه می‌گیریم

$\mathcal{B}_{D,M}$ یک پایه برای $\mathcal{P}_{D,M}$ است.

۳.۲ یکتایی نمایش و نبود پارامترهای تکراری

اکنون باید نشان دهیم که شمارش عناصر این پایه دقیقاً تعداد **پارامترهای مستقل** را می‌دهد. فرض کنید یک چندجمله‌ای، دو نمایش با ضرایب متفاوت روی پایه $\mathcal{B}_{D,M}$ داشته باشد:

$$\sum_{\boldsymbol{\alpha}} a_{\boldsymbol{\alpha}} \mathbf{x}^{\boldsymbol{\alpha}} = \sum_{\boldsymbol{\alpha}} b_{\boldsymbol{\alpha}} \mathbf{x}^{\boldsymbol{\alpha}}, \qquad \forall \mathbf{x} \in \mathbb{R}^D,$$

که هر دو مجموع روی بردارهای توان مجاز گرفته شده‌اند. با تفریق دو طرف خواهیم داشت:

$$\sum_{\boldsymbol{\alpha}} (a_{\boldsymbol{\alpha}} - b_{\boldsymbol{\alpha}}) \mathbf{x}^{\boldsymbol{\alpha}} = 0.$$

از استقلال خطی اعضای پایه نتیجه می‌شود

$$\boxed{a_{\boldsymbol{\alpha}} = b_{\boldsymbol{\alpha}} \quad \text{برای هر } \boldsymbol{\alpha}}$$

بنابراین هر چندجمله‌ای دقیقاً یک بردار ضرایب در این پایه دارد و هیچ ضریب زائدی شمرده نمی‌شود. از سوی دیگر، چون پایه کل فضا را پوشش می‌دهد، هیچ چندجمله‌ای ممکنی نیز از شمارش حذف نشده است. در نتیجه

$$\boxed{P(D,M) = \dim \mathcal{P}_{D,M} = |\mathcal{B}_{D,M}| = \#\left\{\boldsymbol{\alpha} \in \mathbb{Z}_{\geq 0}^D : |\boldsymbol{\alpha}| \leq M\right\}.}$$

اکنون کافی است تعداد بردارهای توان مجاز را بشماریم.

۴.۲ شمارش تعداد کل پارامترهای مستقل

بر اساس قضیهٔ پایه بودن تک‌جمله‌ای‌های متمایز و یکتایی نمایش چندجمله‌ای، تعداد پارامترهای مستقل برابر با تعداد بردارهای توان $\boldsymbol{\alpha} \in \mathbb{Z}_{\geq 0}^D$ است که شرط زیر را ارضا می‌کنند:

$$\alpha_1 + \alpha_2 + \cdots + \alpha_D \leq M.$$

برای شمارش این بردارها، یک متغیر کمکی α_0 تعریف می‌کنیم:

$$\alpha_0 = M - \sum_{i=1}^{D} \alpha_i.$$

از آنجا که مجموع توان‌ها حداکثر M است، داریم $\alpha_0 \geq 0$. بنابراین شرط اولیه معادل معادلهٔ زیر خواهد بود:

$$\alpha_0 + \alpha_1 + \cdots + \alpha_D = M, \qquad \alpha_i \in \mathbb{Z}_{\geq 0} \quad (i = 0, \ldots, D).$$

این تبدیل یک تناظر یک‌به‌یک میان بردارهای توان مجاز و جواب‌های معادلهٔ جدید برقرار می‌کند؛ زیرا به ازای هر $(\alpha_1, \ldots, \alpha_D)$، مقدار α_0 به‌طور یکتا تعیین می‌شود. از طرف دیگر، حذف α_0 از هر جواب معادلهٔ جدید، یک بردار توان مجاز به دست می‌دهد.

در نتیجه، کافی است تعداد جواب‌های صحیح نامنفی معادلهٔ اخیر را محاسبه کنیم.

استفاده از اصل ستاره و میله [1]

[1] Stars and Bars

طبق این اصل، تعداد جواب‌های صحیح نامنفی معادلهٔ

$$z_1 + z_2 + \cdots + z_k = n$$

برابر است با

$$\binom{n+k-1}{k-1}.$$

برای اثبات این رابطه، n ستاره را در یک ردیف قرار می‌دهیم و با استفاده از $k-1$ میله، آن‌ها را به k گروه تقسیم می‌کنیم. تعداد ستاره‌های گروه i مقدار z_i را مشخص می‌کند. گروه‌های خالی نیز مجاز هستند؛ بنابراین میله‌ها می‌توانند در کنار یکدیگر یا در ابتدا و انتهای چیدمان قرار گیرند.

هر جواب معادله دقیقاً با یک چیدمان از n ستاره و $k-1$ میله متناظر است. در مجموع $n+k-1$ جایگاه داریم که انتخاب $k-1$ جایگاه برای میله‌ها، تعداد چیدمان‌های ممکن را تعیین می‌کند.

اکنون در مسئلهٔ ما، تعداد متغیرها $k = D+1$ و مجموع آن‌ها $n = M$ است. پس تعداد جواب‌ها برابر خواهد بود با

$$\begin{aligned} P(D, M) &= \binom{M + (D+1) - 1}{(D+1) - 1} \\ &= \binom{D+M}{D} \\ &= \binom{D+M}{M}. \end{aligned}$$

بنابراین تعداد پارامترهای مستقل یک چندجمله‌ای عمومی از درجهٔ حداکثر M در فضای Dبعدی برابر است با

$$\boxed{P(D, M) = \binom{D+M}{M} = \frac{(D+M)!}{D!\,M!}.}$$

لازم به ذکر است که تک‌جمله‌ای ثابت نیز در این شمارش لحاظ شده است؛ زیرا بردار توان $\boldsymbol{\alpha} = \mathbf{0}$ شرط درجه را ارضا می‌کند و متناظر با ضریب ثابت چندجمله‌ای است.

۵.۲ تحلیل رشد تعداد پارامترها با افزایش بعد

برای بررسی ارتباط تعداد پارامترها با بعد فضای ورودی، باید میان حالت‌های مختلف رشد D و M تمایز قائل شویم.

۱.۵.۲ حالت اول: درجه M ثابت و بعد D متغیر

رابطهٔ به‌دست‌آمده را می‌توان به شکل زیر بازنویسی کرد:

$$\begin{aligned} P(D, M) &= \frac{(D+1)(D+2)\cdots(D+M)}{M!} \\ &= \frac{D^M}{M!} \prod_{j=1}^{M} \left(1 + \frac{j}{D}\right). \end{aligned}$$

از آنجا که M ثابت است، تعداد عوامل ضرب متناهی و مستقل از D است. بنابراین با استفاده از قضیهٔ حد حاصل‌ضرب داریم:

$$\lim_{D\to\infty}\frac{P(D,M)}{D^M/M!}=\lim_{D\to\infty}\prod_{j=1}^{M}\left(1+\frac{j}{D}\right)$$
$$=\prod_{j=1}^{M}\lim_{D\to\infty}\left(1+\frac{j}{D}\right)$$
$$=\prod_{j=1}^{M}1=1.$$

طبق تعریف هم‌ارزی مجانبی، نتیجه می‌گیریم:

$$\boxed{P(D,M)\sim\frac{D^M}{M!}\qquad(D\to\infty,\ M\text{ثابت}).}$$

پس برای درجهٔ ثابت M، تعداد پارامترها نسبت به بعد D رشد چندجمله‌ای از مرتبه D^M دارد.

۲.۵.۲ حالت دوم: افزایش هم‌زمان درجه و بعد

اگر درجه چندجمله‌ای نیز متناسب با بعد افزایش یابد، ممکن است رشد پارامترها نمایی شود.

برای اثبات این موضوع، حالت خاص $M=D$ را در نظر می‌گیریم:

$$P(D,D)=\binom{2D}{D}=\frac{(2D)!}{(D!)^2}.$$

با استفاده از تقریب استرلینگ

$$n!\sim\sqrt{2\pi n}\left(\frac{n}{e}\right)^n,$$

خواهیم داشت:

$$P(D,D)\sim\frac{\sqrt{4\pi D}(2D/e)^{2D}}{2\pi D(D/e)^{2D}}$$
$$=\frac{4^D}{\sqrt{\pi D}}.$$

پس

$$\boxed{P(D,D)\sim\frac{4^D}{\sqrt{\pi D}}.}$$

از آنجا که عامل اصلی رشد، 4^D است، در این حالت تعداد پارامترها با افزایش بعد، رشد نمایی دارد.

بنابراین رشد نمایی برای چندجمله‌ای‌های با درجه کلی حداکثر M، یک نتیجه بدون قید نیست؛ بلکه به نحوه تغییر M نسبت به D وابسته است.

۶.۲ ارتباط تعداد پارامترها با شناسایی مدل

فرض کنید N نمونهٔ آموزشی بدون نویز از یک چندجمله‌ای با P پارامتر مستقل در اختیار داریم. از آنجا که مدل نسبت به ضرایب خود خطی است، می‌توان دستگاه معادلات حاصل از داده‌های آموزشی را به صورت زیر نوشت:

$$\mathbf{y} = \boldsymbol{\Phi}\boldsymbol{\theta}, \qquad \boldsymbol{\Phi} \in \mathbb{R}^{N\times P}, \qquad P = \binom{D+M}{M},$$

که در آن $\boldsymbol{\theta}$ بردار ضرایب و $\boldsymbol{\Phi}$ ماتریس ویژگی‌های چندجمله‌ای نمونه‌های آموزشی است.

برای شناسایی یکتای ضرایب، لازم است $\boldsymbol{\Phi}$ رتبه ستونی کامل داشته باشد؛ یعنی

$$\operatorname{rank}(\boldsymbol{\Phi}) = P.$$

اما از آنجا که

$$\operatorname{rank}(\boldsymbol{\Phi}) \le \min(N, P),$$

شرط لازم برای شناسایی یکتا عبارت است از

$$\boxed{N \ge P.}$$

برای بررسی پیامد نقض این شرط، فرض کنید $N < P$. طبق قضیهٔ رتبه و پوچی، بردار ناصفر $\mathbf{v} \in \ker(\boldsymbol{\Phi})$ وجود دارد؛ بنابراین اگر $\boldsymbol{\theta}_0$ یک جواب دستگاه باشد، برای هر $t \in \mathbb{R}$، بردار

$$\boldsymbol{\theta}_t = \boldsymbol{\theta}_0 + t\mathbf{v}$$

نیز جواب است؛ زیرا

$$\boldsymbol{\Phi}\boldsymbol{\theta}_t = \boldsymbol{\Phi}\boldsymbol{\theta}_0 + t\boldsymbol{\Phi}\mathbf{v} = \mathbf{y}.$$

با این حال، پیش‌بینی این مدل‌ها برای یک ورودی جدید $\mathbf{x}$ برابر است با

$$\boxed{f_t(\mathbf{x}) = f_0(\mathbf{x}) + t\,\boldsymbol{\phi}(\mathbf{x})^T\mathbf{v}.}$$

از آنجا که $\mathbf{v} \neq \mathbf{0}$ و تک‌جمله‌ای‌های متمایز مستقل خطی هستند، حداقل یک ورودی $\mathbf{x}^*$ وجود دارد که

$$\boldsymbol{\phi}(\mathbf{x}^*)^T\mathbf{v} \neq 0.$$

در نتیجه، با تغییر t می‌توان پیش‌بینی مدل را در این نقطه به‌صورت دلخواه تغییر داد، در حالی که خروجی تمام نمونه‌های آموزشی بدون تغییر باقی می‌ماند.

بنابراین، هنگامی که $N < P$، داده‌های آموزشی به‌تنهایی برای شناسایی یکتای مدل کافی نیستند؛ اما این موضوع لزوماً به معنای ناتوانی مدل در یادگیری یا تعمیم نیست. روش‌هایی مانند منظم‌سازی [۲] و اعمال فرض‌های ساختاری می‌توانند به انتخاب یک مدل مناسب از میان جواب‌های ممکن

[2] Regularization

کمک کنند، هرچند تعمیم خوب را به‌تنهایی تضمین نمی‌کنند.

۷.۲ نتیجه‌گیری و ارتباط با نفرین ابعاد

نشان دادیم که تعداد پارامترهای مستقل یک چندجمله‌ای عمومی از درجهٔ حداکثر M در فضای Dبعدی برابر است با

$$P(D, M) = \binom{D + M}{M}.$$

برای درجهٔ ثابت M، این تعداد از مرتبه $\Theta(D^M)$ رشد می‌کند؛ اما در صورتی که درجه همراه با بعد افزایش یابد، رشد می‌تواند **نمایی** باشد.

از سوی دیگر، برای شناسایی یکتای ضرایب در حالت بدون نویز و بدون فرض‌های اضافی بر پارامترها، لازم است تعداد نمونه‌های آموزشی حداقل برابر با تعداد پارامترها باشد:

$$\boxed{N \geq P(D, M) = \binom{D + M}{M}.}$$

بنابراین افزایش بعد فضای ورودی، با افزایش تعداد پارامترهای مدل، می‌تواند نیاز به داده‌های آموزشی بیشتر و هزینهٔ محاسباتی بالاتر را به همراه داشته باشد.

این افزایش پیچیدگی، یکی از جلوه‌های نفرین ابعاد [3] در مدل‌های چندجمله‌ای است؛ هرچند رشد تعداد پارامترها لزوماً در تمام حالت‌ها نمایی نیست.

۳ بعد وی‌سی

> بعد وی‌سی (VC Dimension) چیست؟ این مفهوم را با جزئیات توضیح دهید.

پاسخ

۱.۳ تعریف ریاضی بعد وی‌سی

در یادگیری ماشین، یکی از مسائل اساسی، سنجش ظرفیت یا توان بیان یک خانواده از مدل‌ها است. برای مثال، یک مدل ممکن است بتواند داده‌های آموزشی را کاملاً یاد بگیرد، اما روی داده‌های جدید عملکرد مناسبی نداشته باشد.

بعد وی‌سی[4] معیاری ترکیبیاتی برای سنجش ظرفیت یک **کلاس فرضیه**[5] در مسائل دسته‌بندی دودویی[6] است. این معیار مشخص می‌کند یک کلاس از مدل‌ها تا چه اندازه توانایی بازتولید برچسب‌گذاری‌های دلخواه روی مجموعه‌های متناهی از نقاط را دارد.

فرض کنید $\mathcal{X}$ فضای ورودی و

$$\mathcal{H} \subseteq \{h : \mathcal{X} \to \{0, 1\}\}$$

یک کلاس فرضیه باشد.

همچنین مجموعه‌ای از n نقطه متمایز را به صورت زیر در نظر بگیرید:

[3] Curse of Dimensionality
[4] Vapnik–Chervonenkis Dimension
[5] Hypothesis Class
[6] Binary Classification

$$S = \{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_n\} \subseteq \mathcal{X}.$$

هر فرضیه $h \in \mathcal{H}$، یک بردار برچسب روی این نقاط تولید می‌کند:

$$\big(h(\mathbf{x}_1), \ldots, h(\mathbf{x}_n)\big) \in \{0,1\}^n.$$

مجموعه تمام برچسب‌گذاری‌های قابل تولید توسط کلاس فرضیه روی S را چنین تعریف می‌کنیم:

$$\mathcal{H}(S) = \left\{ \big(h(\mathbf{x}_1), \ldots, h(\mathbf{x}_n)\big) \ : \ h \in \mathcal{H} \right\}.$$

از آنجا که هر نقطه می‌تواند یکی از دو برچسب صفر یا یک را دریافت کند، تعداد تمام برچسب‌گذاری‌های ممکن برابر 2^n است. بنابراین همواره داریم:

$$|\mathcal{H}(S)| \leq 2^n.$$

۱.۱.۳ تعریف مفهوم شَقّه کردن

می‌گوییم کلاس فرضیه $\mathcal{H}$ مجموعه S را **شَقّه می‌کند**[۷] اگر بتواند تمام 2^n برچسب‌گذاری ممکن روی نقاط آن را محقق کند؛ یعنی

$$\boxed{\mathcal{H}(S) = \{0,1\}^n.}$$

به بیان دقیق‌تر،

$$\boxed{\forall \mathbf{y} \in \{0,1\}^n, \quad \exists h \in \mathcal{H} : \quad h(\mathbf{x}_i) = y_i \quad \forall i \in \{1, \ldots, n\}.}$$

نکته مهم در این تعریف، ترتیب سورها است: برای هر برچسب‌گذاری دلخواه، باید حداقل یک فرضیه وجود داشته باشد که آن برچسب‌گذاری را محقق کند. این فرضیه می‌تواند برای برچسب‌گذاری‌های مختلف، متفاوت باشد.

۲.۱.۳ تعریف بعد وی‌سی

بعد وی‌سی کلاس فرضیه $\mathcal{H}$، بزرگ‌ترین تعداد نقاطی است که حداقل یک مجموعه با آن تعداد نقطه توسط $\mathcal{H}$ شقّه شود.

تعریف رسمی آن عبارت است از:

$$\boxed{\mathrm{VCdim}(\mathcal{H}) = \sup \left\{ |S| : S \subseteq \mathcal{X}, \ S \text{ توسط } \mathcal{H} \text{ شقّه شود} \right\}.}$$

اگر مجموعه‌هایی با اندازه دلخواه بزرگ قابل شقّه کردن باشند، بعد وی‌سی نامتناهی است.

از این تعریف، دو اصل مهم برای اثبات بعد وی‌سی نتیجه می‌شود:

- برای اثبات $\mathrm{VCdim}(\mathcal{H}) \geq d$، کافی است یک مجموعه d نقطه‌ای پیدا کنیم که توسط $\mathcal{H}$ شقّه شود.
- برای اثبات $\mathrm{VCdim}(\mathcal{H}) \leq d$، باید نشان دهیم هیچ مجموعه‌ای از $d+1$ نقطه متمایز قابل شقّه کردن نیست.

[7] Shattering

۲.۳ مثال: دسته‌بندهای آستانه‌ای

کلاس فرضیه زیر را روی محور حقیقی در نظر بگیرید:

$$\mathcal{H}_{\text{thr}} = \{h_t(x) = \mathbb{I}\{x \geq t\} : t \in \mathbb{R}\},$$

که در آن $\mathbb{I}$ تابع شاخص است. نشان می‌دهیم:

$$\boxed{\text{VCdim}(\mathcal{H}_{\text{thr}}) = 1.}$$

۱.۲.۳ اثبات کران پایین

یک نقطه دلخواه x_1 را در نظر بگیرید. با انتخاب $t > x_1$ برچسب صفر، و با انتخاب $t \leq x_1$ برچسب یک تولید می‌شود. پس هر دو برچسب‌گذاری ممکن روی این نقطه قابل تحقق‌اند و بنابراین

$$\text{VCdim}(\mathcal{H}_{\text{thr}}) \geq 1.$$

۲.۲.۳ اثبات کران بالا

دو نقطه متمایز دلخواه $x_1 < x_2$ را در نظر بگیرید. برچسب‌گذاری

$$h_t(x_1) = 1, \qquad h_t(x_2) = 0$$

امکان‌پذیر نیست؛ زیرا شرط اول ایجاب می‌کند $t \leq x_1$، و در نتیجه $t < x_2$ خواهد بود؛ پس الزاماً $h_t(x_2) = 1$ است. بنابراین هیچ مجموعه دو نقطه‌ای شقّه نمی‌شود و

$$\text{VCdim}(\mathcal{H}_{\text{thr}}) \leq 1.$$

با ترکیب دو کران به دست می‌آوریم:

$$\boxed{\text{VCdim}(\mathcal{H}_{\text{thr}}) = 1.}$$

این مثال نشان می‌دهد که نامتناهی بودن تعداد فرضیه‌ها لزوماً به معنای نامتناهی بودن بعد وی‌سی نیست؛ زیرا t می‌تواند هر عدد حقیقی باشد، اما بعد وی‌سی این کلاس برابر یک است.

۳.۳ یک کاربرد بعد وی‌سی: تابع رشد و لم سائر–شلاه (بدون اثبات)

۱.۳.۳ تابع رشد و معنای آن

بعد وی‌سی مشخص می‌کند بزرگ‌ترین تعداد نقاطی که دست‌کم یک مجموعه با آن تعداد نقطه قابل شقّه کردن است، چقدر است. حال اگر n از بعد وی‌سی بزرگ‌تر باشد، کلاس فرضیه نمی‌تواند تمام 2^n برچسب‌گذاری را ایجاد کند؛ اما چند برچسب‌گذاری متفاوت می‌تواند بسازد؟

فرض کنید $S = \{x_1, \ldots, x_n\}$ مجموعه‌ای از n نقطه متمایز باشد. مجموعه

$$\mathcal{H}(S) = \big\{\big(h(x_1), \ldots, h(x_n)\big) : \ h \in \mathcal{H}\big\}$$

شامل **بردارهای برچسب متمایزی** است که فرضیه‌های کلاس $\mathcal{H}$ روی نقاط S تولید می‌کنند. بنابراین $|\mathcal{H}(S)|$ تعداد **الگوهای برچسب‌گذاری** قابل تحقق روی S است؛ نه تعداد نقاط S و نه تعداد کل فرضیه‌های $\mathcal{H}$. چند فرضیه مختلف ممکن است روی S دقیقاً یک بردار برچسب یکسان تولید کنند که فقط یک بار شمارش می‌شود.

برای مثال، به همان دسته‌بندهای آستانه‌ای برگردیم. اگر $x_1 < x_2 < x_3$، تنها بردارهای برچسب ممکن عبارت‌اند از

$$\mathcal{H}_{\text{thr}}(S) = \big\{(0,0,0),\ (0,0,1),\ (0,1,1),\ (1,1,1)\big\}.$$

پس $|\mathcal{H}_{\text{thr}}(S)| = 4$، در حالی که در حالت کلی $2^3 = 8$ برچسب‌گذاری دودویی برای سه نقطه وجود دارد.

چون تعداد الگوهای قابل تحقق ممکن است به انتخاب و جایگاه نقاط بستگی داشته باشد، **تابع رشد** [8] را تعریف می‌کنیم:

$$\boxed{\Pi_{\mathcal{H}}(n) = \max_{\substack{S \subseteq \mathcal{X} \\ |S| = n}} |\mathcal{H}(S)|.}$$

به بیان دیگر، $\Pi_{\mathcal{H}}(n)$ بیشترین تعداد برچسب‌گذاری متمایزی است که کلاس $\mathcal{H}$ می‌تواند روی یک مجموعه مناسب از n نقطه محقق کند. همواره

$$\Pi_{\mathcal{H}}(n) \le 2^n.$$

در مثال آستانه‌ای، با مرتب کردن هر n نقطه متمایز، تنها الگوهای شامل تعدادی صفر و سپس تعدادی یک قابل تحقق‌اند. تعداد این الگوها دقیقاً $n+1$ است؛ پس

$$\boxed{\Pi_{\mathcal{H}_{\text{thr}}}(n) = n + 1.}$$

۲.۳.۳ لم ساوئر–شلاه (بدون اثبات)

اکنون پرسش این است که آیا دانستن بعد وی‌سی، بدون بررسی تک‌تک مجموعه‌های n نقطه‌ای، می‌تواند کرانی برای تابع رشد به دست دهد؟ لم ساوئر–شلاه [9] پاسخی مثبت به این پرسش می‌دهد. در اینجا از اثبات لم صرف‌نظر می‌کنیم و فقط نتیجه و کاربرد آن را بیان می‌کنیم.

اگر $\text{VCdim}(\mathcal{H}) = d < \infty$، آنگاه برای هر عدد صحیح نامنفی n داریم:

$$\boxed{\Pi_{\mathcal{H}}(n) \le \sum_{i=0}^{d} \binom{n}{i}.}$$

در این رابطه، برای $i > n$ مقدار $\binom{n}{i}$ را صفر می‌گیریم. برای نمونه، اگر $d = 2$ و $n = 5$، از میان $2^5 = 32$ برچسب‌گذاری ممکن، کلاس فرضیه می‌تواند حداکثر

$$\Pi_{\mathcal{H}}(5) \le \binom{5}{0} + \binom{5}{1} + \binom{5}{2} = 1 + 5 + 10 = 16$$

برچسب‌گذاری متمایز را روی هر مجموعه پنج نقطه‌ای محقق کند. این یک **کران بالا** است و لزوماً برای هر کلاس فرضیه به تساوی تبدیل نمی‌شود.

همچنین برای d ثابت، مجموع سمت راست از مرتبه حداکثر $O(n^d)$ رشد می‌کند، نه از مرتبه 2^n. در نتیجه، بعد وی‌سی متناهی، رشد تعداد برچسب‌گذاری‌های قابل تحقق را محدود می‌کند؛ حتی اگر تعداد اعضای خود کلاس فرضیه نامتناهی باشد. این یکی از کاربردهای مهم مفهوم بعد وی‌سی در سنجش ظرفیت ترکیبیاتی مدل‌ها است.

---

[8] Growth Function

[9] Sauer-Shelah Lemma